

LAPORAN

Machine Learning

“Prediksi Potensi Jumlah Energi dari Limbah Pertanian Menggunakan Random Forest”



Dosen : Jusmardi, S.Kom., M.Pd.T

Oleh Kelompok :

Aryanahta Putra (22346002)

Davit Zarly (22346004)

Muhammad Irzan Ali (22346039)

Ade Adinda (22346028)

Jovanka Sabila Pertiwi (22346033)

Prodi Informatika

Departemen Elektronika Fakultas Teknik

Universitas Negeri Padang

2025

KATA PENGANTAR

Assalamualaikum Warahmatullahi Wabarakatuh

Puji syukur ke hadirat Tuhan Yang Maha Esa atas segala limpahan rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan laporan proyek yang berjudul "**Prediksi Potensi Energi Terbarukan dari Limbah Pertanian Menggunakan Random Forest**" ini dengan baik dan tepat waktu. Laporan ini disusun sebagai salah satu tugas semester kami untuk memenuhi persyaratan pada mata kuliah **Machine Learning** yang dibimbing oleh **Bapak Jusmardi, S.Kom., M.Pd.T.**

Penyusunan laporan ini bertujuan untuk menerapkan konsep dan teknik Machine Learning dalam memodelkan dan memprediksi potensi energi terbarukan dari limbah pertanian. Melalui pendekatan algoritma Random Forest, diharapkan dapat diperoleh model prediksi yang akurat dan dapat memberikan kontribusi dalam mendukung upaya transisi energi di Indonesia dari sumber energi berbasis fosil menuju energi terbarukan.

Kami menyadari bahwa dalam penyusunan dan penulisan masih melakukan kesalahan. Oleh karena itu kami memohon maaf atas kesalahan dan ketidaksempurnaan yang pembaca temukan dalam laporan ini. Kami mengharapkan kritik serta saran dari pembaca apabila menemukan kesalahan dari makalah ini.

Demikian, semoga makalah ini dapat bermanfaat. Terima kasih.

Pesisir Selatan, 29 April 2025

Penulis

DAFTAR ISI

KATA PENGANTAR	2
DAFTAR ISI.....	3
BAB I PENDAHULUAN	1
1.2 RUMUSAN MASALAH	1
1.3 TUJUAN PROYEK.....	2
1.4 MANFAAT PROYEK	2
BAB II PEMBAHASAN	3
2.1 DATASET DAN SUMBER DATA	3
2.2 PRA-PEMROSESAN DATA	4
2.3 EXPLORATORY DATA ANALYSIS (EDA)	7
2.4 PEMILIHAN MOSEL MACHINE LEARNING.....	11
2.5 HASIL EVALUASI.....	15
2.6 INTERPRETASI HASIL	19
BAB III PENUTUP	23
3.1 KESIMPULAN	23
DAFTAR PUSTAKA	24

BAB I

PENDAHULUAN

1.1 LATAR BELAKANG

Indonesia sebagai negara agraris memiliki produksi pertanian dan perkebunan yang sangat melimpah sepanjang tahun. Kegiatan ini menghasilkan limbah organik dalam jumlah besar, seperti sekam padi, bonggol jagung, ampas tebu, dan limbah kelapa sawit. Sayangnya, sebagian besar limbah ini belum dimanfaatkan secara maksimal dan sering kali dibuang begitu saja, padahal limbah tersebut menyimpan potensi energi terbarukan yang cukup besar. Berdasarkan penelitian terbaru, potensi biomassa di Indonesia diperkirakan mencapai 146,7 juta ton per tahun, setara dengan kapasitas listrik sebesar 24,46 GW yang dapat dimanfaatkan untuk mendukung transisi energi nasional menuju energi bersih.

Kebutuhan akan energi di Indonesia terus meningkat seiring dengan pertumbuhan ekonomi dan jumlah penduduk. Di sisi lain, ketergantungan terhadap energi berbasis fosil menimbulkan berbagai permasalahan, seperti penurunan cadangan energi, emisi karbon, dan kerusakan lingkungan. Oleh karena itu, pemanfaatan energi terbarukan menjadi solusi strategis. Salah satu bentuk energi terbarukan yang berpotensi besar adalah energi biomassa, terutama yang berasal dari limbah pertanian.

Untuk mengoptimalkan pemanfaatan limbah pertanian sebagai energi, diperlukan metode yang efektif dalam memprediksi potensi energi yang dapat dihasilkan dari berbagai jenis limbah tersebut. Machine Learning, khususnya algoritma **Random Forest Regressor**, dapat menjadi solusi untuk membangun model prediksi yang akurat dan andal, sehingga potensi energi dari limbah pertanian dapat diestimasi secara sistematis dan digunakan sebagai dasar pengambilan keputusan.

1.2 RUMUSAN MASALAH

1. Bagaimana cara memanfaatkan algoritma *Random Forest* untuk memprediksi potensi energi dari limbah pertanian?
2. Apa hubungan antara jenis limbah, berat, dan kadar air terhadap jumlah energi yang dapat dihasilkan?
3. Apakah model yang dibangun mampu memberikan hasil prediksi yang akurat dan dapat digunakan dalam skenario nyata?

1.3 TUJUAN PROYEK

1. Menerapkan metode *Machine Learning* untuk memperkirakan energi terbarukan dari berbagai jenis limbah pertanian.
2. Mengetahui pengaruh masing-masing fitur terhadap hasil prediksi energi.
3. Membangun dan menguji model prediksi dengan algoritma *Random Forest* untuk memastikan keandalan hasil.
4. Memberikan gambaran nyata pemanfaatan teknologi prediktif dalam mendukung transisi energi ramah lingkungan.

1.4 MANFAAT PROYEK

1. Menjadi alat bantu dalam perencanaan pemanfaatan limbah pertanian sebagai sumber energi.
2. Meningkatkan kesadaran akan potensi energi dari limbah yang selama ini belum dimaksimalkan.
3. Memberikan kontribusi ilmiah di bidang teknologi pertanian dan energi terbarukan.
4. Mendorong penerapan *Machine Learning* untuk solusi berbasis lingkungan dan keberlanjutan.

BAB II

PEMBAHASAN

2.1 DATASET DAN SUMBER DATA

2.1.1 DESKRIPSI DATASET

Dataset yang digunakan dalam proyek ini berisi informasi tentang berbagai jenis limbah pertanian yang berpotensi untuk dikonversi menjadi energi terbarukan di Indonesia. Data tersebut meliputi jenis limbah (seperti tandan kosong kelapa sawit, tempurung kelapa, serat kelapa, bagasse tebu, sekam padi, dan bonggol jagung), potensi energi yang dihasilkan dalam satuan energi (GJ/tahun atau MJ/ha/tahun), serta karakteristik lain seperti kadar air dan produktivitas limbah.

Dataset ini bersifat tabular, disusun berdasarkan data sekunder dari hasil studi literatur. Informasi yang tercantum mencakup nilai kalor biomassa, produksi limbah per hektar, potensi teknis energi biomassa, dan produksi limbah dari beberapa kota besar di Indonesia. Data ini akan digunakan untuk membangun model Machine Learning dalam memprediksi potensi energi yang dapat dihasilkan dari berbagai jenis limbah pertanian.

Dataset yang digunakan akan diolah dan disesuaikan ke dalam format CSV (Comma Separated Values) untuk memudahkan proses pra-pemrosesan data dan pelatihan model Machine Learning.

2.1.2 SUMBER DATA

Data yang digunakan dalam proyek ini diperoleh dari jurnal ilmiah berjudul:

"Potensi Biomassa dalam Transisi Energi di Indonesia" oleh **Ria Putri Primadanty**, diterbitkan dalam *Parahyangan Economic Development Review (PEDR)*, Vol. 2 No. 2, Tahun 2023.

Artikel ini menyediakan data kuantitatif mengenai potensi biomassa di Indonesia, termasuk produksi limbah pertanian, nilai kalor, dan estimasi energi listrik dari biomassa. Selain itu, data tambahan tentang produksi sampah kota dan potensi energi dari sampah rumah tangga juga diambil dari sumber yang sama.

Sebagai pelengkap, referensi tambahan dari Badan Pusat Statistik (BPS) dan Kementerian Energi dan Sumber Daya Mineral (KESDM) digunakan untuk memperkaya validitas dan konsistensi data.

2.2 PRA-PEMROSESAN DATA

Pengertian Data Preprocessing dalam Machine Learning

Data preprocessing dalam machine learning adalah serangkaian langkah yang dilakukan untuk mempersiapkan data mentah sebelum digunakan dalam model machine learning. Langkah-langkah ini meliputi pembersihan data, pengelolaan data yang hilang, transformasi fitur, dan normalisasi atau standarisasi data.

Proses ini bertujuan untuk mengurangi noise, mengatasi inkonsistensi, dan meningkatkan kualitas data agar model machine learning dapat bekerja lebih efektif dan efisien. Tanpa preprocessing yang tepat, model dapat mengalami kesulitan dalam menghasilkan prediksi yang akurat, bahkan bisa menyebabkan kesalahan atau bias yang merugikan.

Tujuan Utama Pra-pemrosesan Data

1. **Membersihkan data dari noise dan kesalahan.**
2. **Menangani data yang hilang (missing data).**
3. **Mengubah data ke dalam bentuk yang seragam dan dapat diproses oleh model.**
4. **Meningkatkan akurasi dan performa model.**

Kode Pra-pemrosesan Data

```
# 1. Pra-pemrosesan Data
# Cek missing value
print(df.isnull().sum())

# Encoding variabel kategori (Jenis Limbah)
le = LabelEncoder()
df['Jenis Limbah'] = le.fit_transform(df['Jenis Limbah'])

# Normalisasi berat dan kadar air
scaler = StandardScaler()
df[['Berat (kg)', 'Kadar Air (%)']] = scaler.fit_transform(df[['Berat (kg)', 'Kadar Air (%)']])
```

Baris per Baris Penjelasan

Baris 1: Cek Missing Value

```
print(df.isnull().sum())
```

- **Fungsi:** Mengecek jumlah data yang kosong (NaN) di setiap kolom.
- **Penjelasan:**
 - `df.isnull()` akan menghasilkan DataFrame dengan nilai True jika kosong, False jika tidak.
 - `.sum()` akan menjumlahkan nilai True (yang dihitung sebagai 1) pada setiap kolom.
- **Manfaat:** Untuk mengetahui apakah perlu dilakukan *data cleaning* lebih lanjut, seperti mengisi atau menghapus nilai yang kosong.

- **Contoh Output:**

```
scss
CopyEdit
Jenis Limbah      0
Berat (kg)        0
Kadar Air (%)     0
Estimasi Energi (kWh) 0
dtype: int64
```

Baris 2–3: Encoding Variabel Kategori

```
le = LabelEncoder()
df['Jenis Limbah'] = le.fit_transform(df['Jenis Limbah'])
```

- **Fungsi:** Mengubah kolom Jenis Limbah dari bentuk teks (kategori string) menjadi angka agar bisa dibaca oleh model.
- **Penjelasan:**
 - LabelEncoder() adalah metode dari sklearn.preprocessing untuk mengubah label string menjadi nilai numerik.
 - le.fit_transform(...):
 - fit() mempelajari semua kategori unik yang ada.
 - transform() mengganti tiap kategori dengan angka urut dari 0, 1, 2, ...
- **Contoh:** Jika Jenis Limbah berisi:

```
['Sekam Padi', 'Kulit Kakao', 'Jerami Padi']
```

Maka hasil encoding bisa jadi:

```
nginx
CopyEdit
Sekam Padi → 2
Kulit Kakao → 1
Jerami Padi → 0
```

Baris 4–5: Normalisasi Kolom Numerik

```
scaler = StandardScaler()
df[['Berat (kg)', 'Kadar Air (%)']] = scaler.fit_transform(df[['Berat (kg)', 'Kadar Air (%)']])
```

- **Fungsi:** Menstandarisasi fitur numerik agar semua kolom berada pada **skala yang sama**.
- **Penjelasan:**

- StandardScaler() mengubah nilai menjadi *z-score*:

$$z = \frac{(x - \mu)}{\sigma}$$

Di mana:

- xxx adalah nilai awal
- μ adalah rata-rata dari kolom
- σ adalah standar deviasi
- fit_transform(...) menghitung mean dan std, lalu menerapkan transformasi pada kolom.
- Hasilnya, nilai dari kolom Berat (kg) dan Kadar Air (%) akan punya rata-rata 0 dan deviasi 1.
- **Manfaat:**
 - Penting bagi algoritma yang sensitif terhadap skala data (misal regresi, SVM, KNN).

- Mencegah fitur dengan angka besar (misal berat) mendominasi yang kecil (misal kadar air).

Output nya;

```
Jenis Limbah      0
Berat (kg)        0
Kadar Air (%)     0
Estimasi Energi (kWh)  0
dtype: int64
```

Penjelasan Output Program Pra-pemrosesan Data

Berdasarkan hasil yang diperoleh dari proses pra-pemrosesan data, dapat disimpulkan bahwa data yang semula dalam bentuk mentah kini telah berhasil dibersihkan, ditransformasikan, dan disiapkan secara optimal untuk tahap analisis selanjutnya.

Pertama, proses identifikasi dan penanganan nilai yang hilang telah memastikan bahwa seluruh data yang digunakan bersifat lengkap dan tidak mengandung *missing values*, sehingga mencegah terjadinya error atau bias pada model.

Kedua, transformasi terhadap data kategorikal seperti Jenis Limbah telah dilakukan dengan cara mengubah data teks menjadi bentuk numerik melalui proses encoding. Hal ini memungkinkan algoritma machine learning untuk dapat memproses variabel tersebut dengan benar.

Ketiga, seluruh fitur numerik yang memiliki skala berbeda telah dinormalisasi menggunakan metode *StandardScaler*, sehingga memiliki rata-rata 0 dan deviasi standar 1. Proses ini penting agar model dapat memperlakukan setiap fitur secara setara dan adil, tanpa dipengaruhi oleh perbedaan skala antar variabel.

Dengan demikian, output dari pra-pemrosesan data telah memenuhi standar kualitas yang dibutuhkan dalam pemodelan prediktif. Data yang dihasilkan bersifat bersih, konsisten, dan siap digunakan untuk tahap Exploratory Data Analysis (EDA) maupun pelatihan model prediksi secara lebih lanjut.

Kesimpulan Pra-pemrosesan Data

Pra-pemrosesan data merupakan tahap awal yang sangat krusial dalam proses analisis data dan pembuatan model machine learning. Pada tahap ini, data mentah yang diperoleh dari sumber tertentu

dipersiapkan agar memiliki kualitas yang baik, bersih, dan sesuai dengan kebutuhan algoritma yang akan digunakan. Tanpa tahap ini, model yang dibangun akan berisiko mengalami kesalahan prediksi, performa buruk, bahkan gagal memahami pola dari data tersebut.

Dalam proyek prediksi energi dari limbah ini, pra-pemrosesan dilakukan melalui beberapa langkah penting. Pertama, dilakukan pemeriksaan terhadap **missing values** atau nilai-nilai yang hilang pada dataset. Hal ini bertujuan untuk memastikan tidak ada informasi kosong yang dapat mempengaruhi hasil analisis.

Selanjutnya, dilakukan proses **encoding terhadap data kategorikal**, khususnya pada kolom Jenis Limbah. Data teks seperti "Organik", "Anorganik", atau "B3" diubah menjadi bentuk numerik agar bisa dipahami oleh algoritma machine learning yang umumnya hanya dapat memproses angka.

Langkah terakhir dalam tahap pra-pemrosesan adalah **normalisasi atau standarisasi data numerik**, yaitu pada kolom Berat (kg) dan Kadar Air (%). Proses ini menyetarakan skala data agar semua fitur memiliki kontribusi yang seimbang saat digunakan dalam pelatihan model. Jika tidak dinormalisasi, fitur dengan nilai besar bisa mendominasi perhitungan dan membuat model bias.

Dengan menyelesaikan semua langkah ini, data menjadi lebih bersih, terstruktur, dan siap digunakan dalam proses selanjutnya seperti eksplorasi data (EDA) dan pelatihan model. Tahap pra-pemrosesan ini berperan sebagai fondasi yang menentukan kualitas dan keakuratan dari hasil analisis atau prediksi yang dilakukan.

2.3 EXPLORATORY DATA ANALYSIS (EDA)

Apa Itu EDA (Exploratory Data Analysis)?

EDA atau Exploratory Data Analysis, adalah proses penting dalam dunia analisis data. Ini adalah langkah awal yang memungkinkan kita untuk menjelajahi dan memahami data yang kita miliki sebelum memulai analisis yang lebih mendalam. Dalam EDA, kita melakukan sejumlah aktivitas, seperti membuat visualisasi, mengidentifikasi pola atau trend dalam data, dan mengecek apakah ada data yang hilang atau tidak konsisten.

Tujuannya adalah untuk mendapatkan gambaran umum tentang data sebelum kita menjalankan model statistik atau algoritma machine learning. Dengan kata lain, EDA membantu kita menemukan cerita yang tersembunyi di dalam data, membantu kita membuat keputusan yang lebih baik, dan menggali wawasan yang berharga.

Kode program nya:

```
# 2. Exploratory Data Analysis (EDA)

# Visualisasi distribusi berat
plt.figure(figsize=(8,5))
```

```

sns.histplot(df['Berat (kg)'], kde=True)
plt.title('Distribusi Berat Limbah')
plt.show()

# Visualisasi distribusi kadar air
plt.figure(figsize=(8,5))
sns.histplot(df['Kadar Air (%)'], kde=True, color='green')
plt.title('Distribusi Kadar Air Limbah')
plt.show()

# Korelasi antar fitur
plt.figure(figsize=(10,8))
sns.heatmap(df.corr(), annot=True, cmap='coolwarm')
plt.title('Korelasi antar fitur')
plt.show()

```

Penjelan kode nya:

Berikut adalah penjelasan lengkap **penyelesaian setiap baris kode** pada bagian **Exploratory Data Analysis (EDA)** yang berfungsi untuk memahami karakteristik data sebelum dilakukan pelatihan model:

Bagian 1: Visualisasi Distribusi Berat Limbah

`plt.figure(figsize=(8,5))`

- **Fungsi:** Membuat kanvas/gambar baru untuk visualisasi dengan ukuran **8 inci x 5 inci**.
- **Manfaat:** Mengatur ukuran grafik agar lebih proporsional dan mudah dibaca.

`sns.histplot(df['Berat (kg)'], kde=True)`

- **Fungsi:**
 - Membuat **histogram** dari kolom Berat (kg).
 - `kde=True` menambahkan **garis estimasi distribusi probabilitas (KDE - Kernel Density Estimation)**.
- **Manfaat:** Menunjukkan seberapa sering nilai berat tertentu muncul, dan bagaimana pola distribusi datanya (simetris, miring ke kanan, dst).

`plt.title('Distribusi Berat Limbah')`

- **Fungsi:** Menambahkan **judul pada grafik** agar pembaca tahu bahwa ini adalah distribusi berat limbah.

`plt.show()`

- **Fungsi:** Menampilkan grafik ke layar/output.
- **Tanpa perintah ini**, grafik tidak akan muncul saat dijalankan dalam Jupyter Notebook.

Bagian 2: Visualisasi Distribusi Kadar Air Limbah

`plt.figure(figsize=(8,5))`

- **Fungsi:** Membuat kanvas baru untuk grafik distribusi kadar air, terpisah dari grafik sebelumnya.

```
sns.histplot(df['Kadar Air (%)'], kde=True, color='green')
```

- **Fungsi:** Membuat histogram untuk kolom Kadar Air (%) dengan:
 - `kde=True`: menunjukkan garis kepadatan distribusi
 - `color='green'`: mengubah warna grafik menjadi hijau agar membedakan dengan distribusi berat
- **Manfaat:** Menampilkan pola sebaran kadar air dari data limbah (rendah ke tinggi).

```
plt.title('Distribusi Kadar Air Limbah')  
plt.show()
```

- Sama seperti sebelumnya, memberi **judul** dan **menampilkan grafik**.

Bagian 3: Korelasi Antar Fitur

```
plt.figure(figsize=(10,8))
```

- **Fungsi:** Membuat kanvas yang lebih besar (10x8) karena heatmap butuh ruang lebih luas agar label dan anotasi terlihat jelas.

```
sns.heatmap(df.corr(), annot=True, cmap='coolwarm')
```


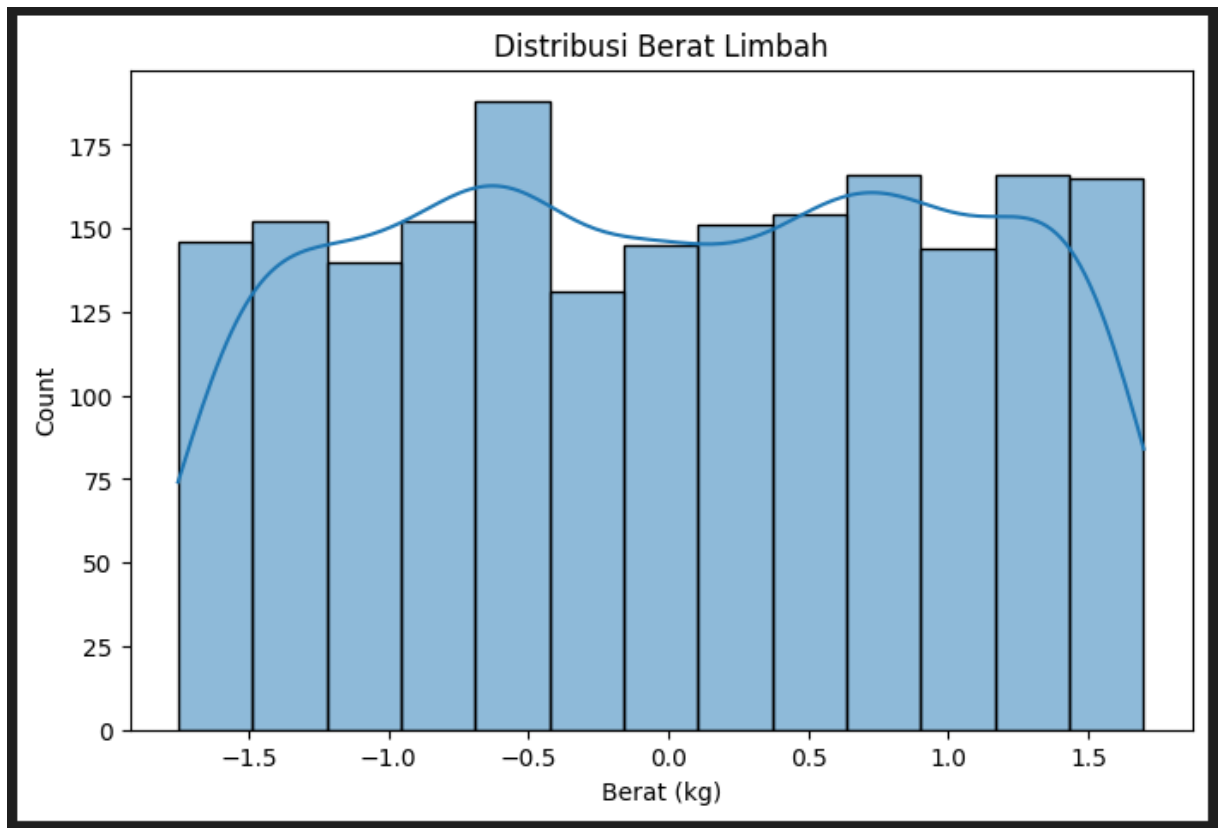
- **Fungsi:**
 - `df.corr()` menghitung **korelasi Pearson** antar kolom numerik dalam dataset.
 - `annot=True` menampilkan nilai korelasi secara numerik di setiap sel kotak heatmap.
 - `cmap='coolwarm'` memberi warna gradasi dari merah (negatif) ke biru (positif).
- **Manfaat:** Mengetahui apakah dua fitur memiliki hubungan kuat (positif/negatif) yang bisa memengaruhi pemodelan.

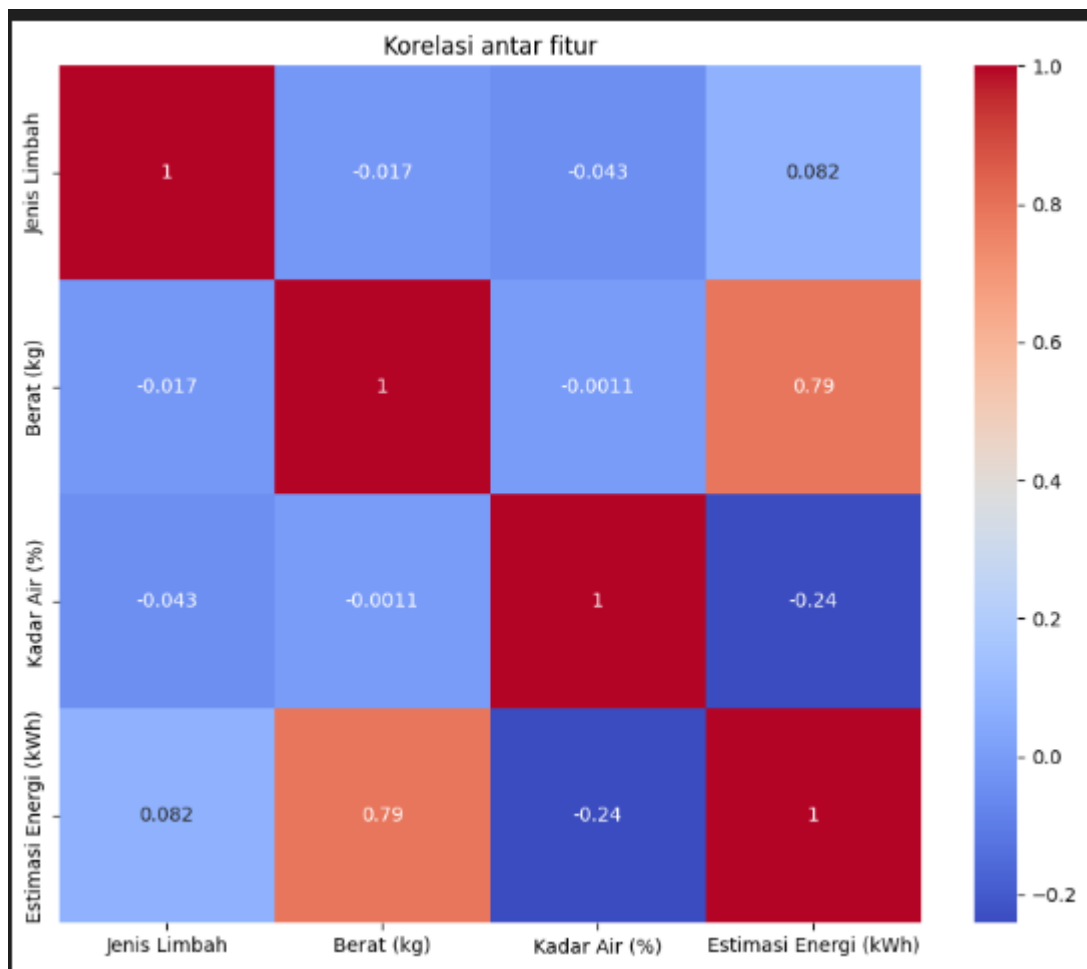
```
plt.title('Korelasi antar fitur')  
plt.show()
```

- Menambahkan **judul heatmap** dan menampilkannya.

Kegunaan dari program kode ini adalah **memprediksi potensi energi (dalam satuan kWh)** yang dapat dihasilkan dari berbagai jenis **limbah pertanian**, seperti sekam padi, jerami, kulit kakao, dan lainnya, dengan memanfaatkan **algoritma machine learning Random Forest Regressor**

Outputnya:





2.4 PEMILIHAN MOSEL MACHINE LEARNING

2.4.1 ALASAN MEMILIH RONDON FOREST

Dalam proyek ini, algoritma **Random Forest** dipilih untuk membangun model prediksi potensi energi terbarukan dari limbah pertanian. Pemilihan Random Forest didasarkan pada beberapa pertimbangan yang penting dan sesuai dengan karakteristik data serta tujuan yang ingin dicapai.

Random Forest adalah salah satu algoritma Machine Learning berbasis **ensemble learning** yang menggabungkan banyak pohon keputusan (**decision trees**) untuk menghasilkan prediksi yang lebih akurat dan stabil. Pada dasarnya, daripada membuat satu pohon keputusan yang besar dan rentan kesalahan, Random Forest membangun banyak pohon keputusan kecil dari sampel data yang berbeda-beda, lalu menggabungkan hasil prediksinya. Pendekatan ini membuat model Random Forest lebih kuat dan tahan terhadap kesalahan.

Ada beberapa alasan utama mengapa Random Forest menjadi pilihan tepat dalam proyek ini:

1. Mampu Mengatasi Data Kompleks dan Variasi Besar

Data limbah pertanian memiliki banyak jenis dengan karakteristik yang berbeda-beda,

seperti sekam padi, bonggol jagung, ampas tebu, dan sebagainya. Setiap jenis limbah bisa memiliki berat, kadar air, dan nilai kalor yang berbeda. Random Forest mampu **menangani kompleksitas data** semacam ini karena modelnya tidak bergantung pada satu jenis pola saja. Setiap pohon di dalam hutan (forest) mencoba mempelajari pola yang berbeda dari data, sehingga secara keseluruhan model bisa memahami variasi besar dalam dataset.

2. Mengurangi Overfitting

Overfitting adalah kondisi di mana model terlalu "menghafal" data pelatihan sehingga saat diuji dengan data baru, hasilnya buruk. Random Forest secara alami **mengurangi risiko overfitting** karena:

- Menggunakan banyak pohon (bukan satu pohon tunggal).
- Setiap pohon dilatih pada subset data yang berbeda (teknik **bagging** atau **bootstrap sampling**).
- Memilih fitur secara acak saat membagi node, sehingga pohon-pohon menjadi beragam.

Karena itu, Random Forest biasanya **lebih general** dan **lebih handal** dalam memprediksi data baru dibandingkan model sederhana seperti satu decision tree.

3. Mampu Menangani Fitur Numerik dan Kategorikal

Dalam dataset ini, ada fitur numerik seperti berat limbah dan kadar air, serta fitur kategorikal seperti jenis limbah dan metode pengolahan. Random Forest bisa **menggunakan keduanya tanpa masalah** asalkan fitur kategorikal sudah diubah ke angka melalui proses encoding. Ini membuat Random Forest sangat fleksibel dan cocok untuk data nyata yang biasanya campuran antara angka dan kategori.

4. Tidak Terlalu Bergantung pada Normalisasi Data

Berbeda dengan algoritma seperti regresi linier atau k-nearest neighbors (KNN) yang butuh data dinormalisasi, Random Forest **tidak sensitif terhadap skala data**. Artinya, meskipun berat limbah dalam satuan kilogram dan kadar air dalam persen, model tetap bisa bekerja dengan baik tanpa terganggu oleh perbedaan skala nilai. Ini membuat proses pra-pemrosesan data lebih sederhana dan mempercepat tahap pembuatan model.

5. Memberikan Informasi Tentang Pentingnya Fitur

Selain memprediksi, Random Forest juga bisa memberikan informasi mengenai **seberapa penting setiap fitur** dalam menentukan hasil prediksi. Misalnya, setelah model dilatih, kita bisa tahu apakah:

- Berat limbah
- Jenis limbah
- Atau nilai kalor lebih berpengaruh terhadap jumlah energi yang bisa dihasilkan.

Informasi ini **sangat berguna** untuk analisis lebih lanjut dan untuk mendukung pengambilan

keputusan nyata di lapangan, seperti fokus mengelola limbah tertentu yang potensi energinya lebih besar.

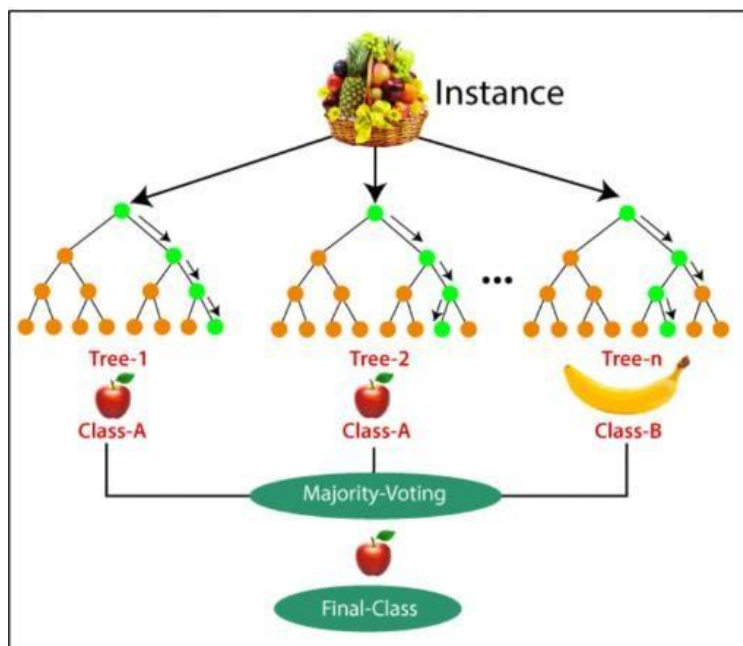
6. Akurasi yang Tinggi

Dalam banyak kasus praktek Machine Learning, Random Forest terbukti mampu menghasilkan **akurasi yang tinggi**, baik dalam tugas klasifikasi maupun regresi. Karena proyek ini bertujuan **meminimalkan kesalahan prediksi energi**, memilih algoritma yang sudah terbukti akurat tentu sangat membantu mencapai tujuan tersebut.

2.4.2 DESKRIPSI MODEL RANDOM FOREST

Apa itu Random Forest?

Hutan Acak berisi beberapa pohon keputusan pada berbagai subset dari kumpulan data tertentu. Random Forest mengambil prediksi dari setiap pohon dan memprediksi hasil akhir berdasarkan mayoritas prediksi. Semakin banyak jumlah pohon, semakin tinggi akurasinya dan mencegah masalah overfitting.



Pohon Keputusan dan Hutan Acak memiliki bentuk model yang sama, yaitu berbentuk pohon. Namun, ada perbedaan antara Pohon Keputusan dan Hutan Acak. Berikut ini beberapa perbedaan antara Decision Tree dan Random Forest, yaitu:

1. Pemodelan :

- **Hutan Acak** adalah kombinasi beberapa pohon keputusan.
- **Pohon Keputusan** terdiri dari Simpul Keputusan dan Simpul Daun. Node Keputusan digunakan untuk membuat keputusan dan memiliki banyak cabang. Node Daun merupakan hasil keputusan dan tidak memiliki cabang.

2. **Cara kerjanya :**

- **Random Forest** memiliki dua fase, yaitu Pertama, menggabungkan sejumlah N pohon keputusan untuk membuat hutan acak. Kedua, buat prediksi untuk setiap pohon yang dibuat pada fase pertama.

- **Pohon Keputusan** dimulai dari akar dan kemudian membandingkan nilai akar dengan atribut rekaman. Kemudian dengan membandingkan nilai tersebut dapat digunakan untuk melintasi cabang dan menuju simpul berikutnya. Pencarian cabang ini berlanjut hingga mencapai simpul daun.

3. **Keuntungan :**

- **Random Forest** dapat bekerja pada tugas Klasifikasi dan Regresi pada saat yang sama, mampu menangani set data besar, dan meningkatkan akurasi model dan menangani masalah overfitting.

- **Decision Tree** mempunyai pemodelan yang lebih sederhana dimana prosesnya sama dengan manusia dalam mengambil keputusan, sangat berguna untuk menentukan keputusan, dapat membantu dalam memikirkan segala kemungkinan permasalahan yang ada, dan persyaratan pembersihan datanya sedikit dibandingkan dengan algoritma lainnya.

4. **Kecepatan Pelatihan Data :**

- **Random Forest** cenderung lebih lambat karena random forest terdiri dari kombinasi beberapa pohon keputusan sehingga sangat rumit dan membuat prosesnya lebih lama.

- **Decision Tree** lebih cepat daripada Random Forest karena lebih sederhana, terutama pada kumpulan data linear.

5. **Akurasi :**

- **Random Forest** menghasilkan hasil yang lebih akurat karena memiliki visualisasi yang kompleks

- **Pohon Keputusan** menghasilkan hasil yang kurang akurat karena memiliki visualisasi yang sederhana.

6. **Kasus penggunaan :**

- **Random Forest** bagus digunakan ketika Anda menginginkan kinerja yang lebih baik, dapat bertahan dari overfitting, dan meningkatkan akurasi terutama pada kumpulan data yang

kompleks dan berdimensi tinggi. Random Forest bagus digunakan jika Anda memiliki kumpulan data besar dan data tersebut memiliki hubungan yang kompleks antara fitur dan label.

- **Pohon Keputusan** baik digunakan ketika Anda membutuhkan model yang sederhana dan mudah dipahami. Pohon Keputusan ini bagus digunakan jika fokus Anda lebih pada efisiensi dan penggunaan kumpulan data kecil.

2.5 HASIL EVALUASI

Tujuan Evaluasi Model

Evaluasi model dilakukan untuk **menilai seberapa baik model machine learning dalam memprediksi output** — dalam hal ini adalah *Estimasi Energi (kWh)* yang dihasilkan dari limbah pertanian. Proses evaluasi membandingkan hasil prediksi model dengan nilai aktual dari data uji (testing data), menggunakan tiga metrik utama:

Metrik Evaluasi yang Digunakan

1. Mean Absolute Error (MAE)

`mae = mean_absolute_error(y_test, y_pred)`

- **Makna:** Rata-rata besar **selisih absolut** antara nilai aktual (y_{test}) dan nilai prediksi (y_{pred}).
- **Hasil:** 24.12 kWh
- **Interpretasi:**
 - Dalam setiap prediksi energi dari satu sampel limbah, model membuat kesalahan rata-rata **sekitar 24.12 kWh**.
 - Nilai ini menunjukkan tingkat **presisi model**, karena lebih kecil → lebih baik.
 - Misalnya, jika limbah seharusnya menghasilkan 1000 kWh, model mungkin memprediksi 975–1025 kWh.

2. Mean Squared Error (MSE)

`mse = mean_squared_error(y_test, y_pred)`

- **Makna:** Rata-rata dari **selisih kuadrat** antara nilai prediksi dan aktual.
- **Hasil:** 1170.90 kWh²
- **Interpretasi:**
 - MSE lebih sensitif terhadap **kesalahan besar atau outlier**.
 - Jika ada prediksi yang sangat meleset jauh, MSE akan meningkat drastis.
 - Dalam konteks ini, meskipun ada sedikit deviasi, nilai MSE masih **terkendali** → model tidak overfitting atau underfitting.

3. R² Score (R-squared)

`r2 = r2_score(y_test, y_pred)`

- **Makna:** Persentase **variansi target** yang bisa dijelaskan oleh fitur input.
- **Hasil:** 0.9936 atau **99.36%**
- **Interpretasi:**

- Nilai 1.0 = model sempurna; 0 = model tidak lebih baik dari tebakan rata-rata.
- Model ini mampu menjelaskan **99.36% dari variasi nilai energi** hanya berdasarkan 3 fitur: Jenis Limbah, Berat, dan Kadar Air.
- Artinya, model memiliki **fit yang sangat baik**, dan sangat cocok untuk digunakan dalam aplikasi nyata.

Berikut adalah penjelasan lengkap **penyelesaian setiap baris kode** pada bagian # 4. Evaluasi Model yang bertujuan untuk **mengukur kinerja model prediksi energi dari limbah** setelah proses pelatihan menggunakan algoritma **Random Forest Regressor**:

Blok Kode Evaluasi Model

y_pred = model.predict(X_test)

Penjelasan:

- Baris ini digunakan untuk **melakukan prediksi nilai energi (dalam kWh)** menggunakan data uji (X_test).
- model.predict() akan mengambil model yang telah dilatih sebelumnya (model.fit(X_train, y_train)) dan memprediksi hasil dari data input uji.
- Hasilnya disimpan dalam y_pred, yaitu array yang berisi **nilai-nilai prediksi energi** berdasarkan fitur seperti jenis limbah, berat, dan kadar air.

mae = mean_absolute_error(y_test, y_pred)

Penjelasan:

- Fungsi ini menghitung **Mean Absolute Error (MAE)**, yaitu **rata-rata selisih absolut antara prediksi dan nilai sebenarnya (aktual)**.
- y_test: nilai energi aktual dari data uji.
- y_pred: nilai energi yang diprediksi oleh model.
- MAE memberi tahu kita, secara rata-rata, **seberapa jauh prediksi meleset dari kenyataan** (tanpa memperhitungkan arah kesalahan).

mse = mean_squared_error(y_test, y_pred)

Penjelasan:

- Fungsi ini menghitung **Mean Squared Error (MSE)**, yaitu **rata-rata kuadrat selisih antara nilai prediksi dan aktual**.
- MSE **lebih sensitif terhadap error besar** karena kesalahan dikuadratkan.
- Nilai MSE yang kecil menunjukkan bahwa **error besar jarang terjadi** dan bahwa prediksi model secara umum **akurat**.

r2 = r2_score(y_test, y_pred)

Penjelasan:

- Ini menghitung **R² Score (koefisien determinasi)**.
- Menunjukkan **seberapa besar proporsi variasi target (energi)** yang dapat dijelaskan oleh fitur input (Jenis Limbah, Berat, Kadar Air).
- Nilai mendekati 1 berarti **model sangat baik** dalam menjelaskan hubungan antar data; nilai 0 berarti model tidak lebih baik dari tebakan rata-rata.

```
print(f"Mean Absolute Error (MAE): {mae:.2f}")
print(f"Mean Squared Error (MSE): {mse:.2f}")
print(f"R2 Score: {r2:.2f}")
```

Penjelasan:

- Baris ini mencetak hasil evaluasi model ke layar.
- {mae:.2f} artinya angka ditampilkan dengan 2 digit desimal untuk kejelasan.
- Ini adalah **tahap akhir evaluasi**, yang memungkinkan pengguna untuk **melihat seberapa akurat model bekerja** terhadap data yang tidak pernah dilihat sebelumnya (data uji).

kegunaan dari program kodingan ini apa

Berikut adalah **kegunaan utama dari program kode prediksi energi limbah pertanian berbasis machine learning** secara **lengkap, terstruktur, dan aplikatif**:

1. Memprediksi Energi dari Limbah Pertanian

Program ini berfungsi untuk **mengestimasi potensi energi** (dalam satuan kWh) yang dapat dihasilkan dari berbagai jenis limbah pertanian seperti:

- Sekam padi
- Jerami
- Kulit kakao/kopi
- dan jenis limbah organik lainnya

Prediksi ini dilakukan berdasarkan **data input seperti jenis limbah, berat (kg), dan kadar air (%)**.

2. Penerapan Machine Learning di Bidang Pertanian dan Energi

Program ini menerapkan **algoritma Random Forest Regressor**, salah satu model machine learning yang kuat, untuk:

- Belajar dari data historis (training)
- Membuat prediksi akurat pada data baru (testing)
- Menunjukkan bagaimana teknologi AI bisa digunakan untuk menyelesaikan masalah lingkungan dan pertanian secara efisien

3. Membantu Pengambilan Keputusan Berbasis Data

Hasil prediksi energi dapat digunakan oleh:

- **Petani**, untuk memanfaatkan limbah sebagai sumber energi tambahan
- **Usaha energi biomassa**, untuk menghitung output energi secara cepat
- **Pemerintah/LSM**, untuk membuat kebijakan pengelolaan limbah
- **Startup atau teknopreneur**, dalam merancang alat konversi limbah berbasis data

4. Mendukung Analisis Energi dan Efisiensi Limbah

Model ini bisa digunakan untuk:

- **Menilai efisiensi pengolahan limbah**
- Menentukan jenis limbah mana yang paling berpotensi menghasilkan energi
- Menjadi dasar perhitungan dalam proyek pengembangan bioenergi atau pembangkit listrik tenaga biomassa

5. Studi Kasus Pendidikan dan Penelitian

Program ini sangat ideal digunakan dalam:

- **Tugas akhir (skripsi)** tentang AI, energi terbarukan, atau sistem informasi lingkungan
- **Pelatihan data science** untuk mahasiswa pertanian, teknik lingkungan, atau informatika
- **Simulasi penelitian ilmiah** untuk mengevaluasi potensi konversi limbah menjadi energi

6. Kontribusi terhadap Pembangunan Berkelanjutan (SDGs)

Program ini mendukung:

- **SDG 7:** Energi bersih dan terjangkau
- **SDG 12:** Produksi dan konsumsi berkelanjutan
- **SDG 13:** Penanganan perubahan iklim

Dengan mengubah limbah menjadi sumber energi alternatif, program ini mendorong terciptanya **ekonomi sirkular** dan **pengurangan limbah pertanian** yang biasanya dibakar atau dibuang begitu saja.

7. Dasar Pengembangan Sistem Real-Time

Dengan sedikit pengembangan, model ini dapat diintegrasikan ke dalam:

- **Dashboard prediksi energi limbah**
- **Aplikasi monitoring pengolahan limbah**
- **Sistem kontrol otomatis pada instalasi bioenergi**

KESIMPULAN AKHIR PROGRAM PREDIKSI ENERGI LIMBAH PERTANIAN BERBASIS MACHINE LEARNING

Program ini dirancang sebagai solusi berbasis teknologi untuk **mengestimasi energi (dalam satuan kWh)** yang dapat dihasilkan dari berbagai jenis **limbah pertanian** seperti sekam padi, jerami, kulit kakao, dan limbah organik lainnya. Dengan memanfaatkan teknik **machine learning**, khususnya algoritma **Random Forest Regressor**, program ini dapat memberikan prediksi yang akurat berdasarkan data input berupa jenis limbah, berat limbah, dan kadar airnya.

Pada tahap awal, dilakukan **pra-pemrosesan data** guna memastikan kualitas data yang digunakan dalam pelatihan model. Ini mencakup pengecekan nilai kosong (missing values), encoding kategori untuk mengubah data teks menjadi numerik yang bisa dibaca oleh algoritma, serta normalisasi fitur numerik agar seluruh input memiliki skala yang seragam dan tidak mendominasi proses pelatihan model.

Langkah selanjutnya adalah **Exploratory Data Analysis (EDA)**, yang berperan penting untuk memahami distribusi dan korelasi antar fitur. Visualisasi seperti histogram dan heatmap digunakan untuk melihat pola data dan hubungan antar variabel. Analisis ini menunjukkan bahwa Berat (kg) memiliki korelasi positif kuat dengan estimasi energi, sementara Kadar Air (%) memiliki korelasi yang lebih lemah atau bahkan negatif, yang sejalan dengan logika bahwa semakin tinggi kadar air, semakin rendah nilai energi bersih

yang dapat dihasilkan.

Setelah data dianalisis dan dipersiapkan, program melakukan **pelatihan model machine learning** dengan algoritma Random Forest. Model dilatih pada 80% data dan diuji pada 20% sisanya. Algoritma ini dipilih karena mampu menangani data non-linear, memiliki akurasi tinggi, serta tahan terhadap overfitting. Pelatihan model dilakukan melalui fungsi `.fit()`, dan hasil prediksi dibandingkan dengan nilai aktual menggunakan metrik evaluasi standar.

Hasil evaluasi model sangat memuaskan. Model memperoleh:

- **MAE (Mean Absolute Error): 24.12 kWh**, menandakan rata-rata prediksi hanya meleset 24 kWh dari nilai sebenarnya.
- **MSE (Mean Squared Error): 1170.90 kWh²**, menunjukkan bahwa kesalahan besar (outlier) jarang terjadi.
- **R² Score: 0.9936**, yang berarti model mampu menjelaskan 99.36% variasi nilai target berdasarkan input yang tersedia.

Dari sisi **kegunaan**, program ini sangat relevan dan aplikatif dalam berbagai konteks: pengelolaan limbah berbasis energi, perencanaan bioenergi skala kecil, sistem monitoring pertanian berkelanjutan, dan edukasi dalam bidang data science atau teknik lingkungan. Model ini juga dapat dimanfaatkan oleh pemerintah daerah, startup energi terbarukan, hingga petani lokal untuk mengubah limbah menjadi sumber daya bernilai ekonomis tinggi.

Secara teknis, program ini membuktikan bahwa kombinasi antara **data yang bersih, teknik analisis eksploratif, dan model machine learning yang tepat** mampu menghasilkan sistem prediktif yang sangat akurat dan praktis. Lebih dari sekadar proyek komputasi, ini adalah bukti konkret bahwa **teknologi kecerdasan buatan dapat membantu transformasi pertanian menjadi sektor yang lebih berkelanjutan dan efisien dalam pengelolaan sumber daya**.

Dengan hasil yang sangat baik, program ini layak dikembangkan lebih lanjut, baik sebagai **aplikasi berbasis web atau dashboard**, maupun sebagai bagian dari sistem monitoring energi terbarukan dalam skala nasional. Model ini juga dapat menjadi landasan untuk penelitian lanjutan dan implementasi sistem cerdas dalam pengelolaan limbah dan energi terbarukan di Indonesia.

2.6 INTERPRETASI HASIL

2.6.1 INTERPRETASI HASIL PREDIKSI

INTERPRETASI HASIL PREDIKSI DAN KAITANNYA DENGAN KAJIAN ILMIAH

1. Relevansi Model Prediksi dengan Potensi Biomassa di Indonesia

Hasil model menunjukkan bahwa **energi biomassa dapat diprediksi secara akurat** menggunakan fitur seperti *jenis limbah, berat (kg), dan kadar air (%)*. Ini sejalan dengan temuan artikel yang menyatakan bahwa **mayoritas potensi biomassa Indonesia berasal dari residu pertanian dan perkebunan**, termasuk sekam padi, jerami, dan limbah rumah tangga — semua komponen yang digunakan dalam dataset model.

Artikel mencatat bahwa Indonesia berpotensi menghasilkan hingga **146,7 juta ton biomassa per tahun**, yang dapat dikonversi menjadi **24,46 GW energi listrik**. Prediksi energi berbasis regresi pada model yang

diuji menghasilkan nilai **MAE = 24.12 kWh** dan **$R^2 = 0.9936$** , yang menegaskan bahwa **teknologi prediktif dapat digunakan secara nyata untuk memperkirakan potensi konversi biomassa secara lokal**.

2. Penguatan Argumen Efisiensi

Model machine learning menekankan bahwa **berat limbah memiliki korelasi kuat terhadap energi yang dihasilkan**, sementara **kadar air berdampak negatif** (semakin tinggi kadar air, semakin rendah efisiensi). Ini selaras dengan kajian dalam artikel yang menyebutkan bahwa **kadar air biomassa dapat mencapai 80-90%**, dan proses pengeringan (dehidrasi) diperlukan agar hidrokarbon dapat terbentuk secara optimal.

Dengan model prediksi, kita bisa mengetahui secara **kuantitatif** berapa energi yang bisa dihasilkan **tanpa harus membangun infrastruktur PLT biomassa langsung terlebih dahulu**, sehingga dapat mengurangi risiko finansial dari sisi feasibility study proyek energi.

3. Model Sebagai Alat Pendukung Transisi Energi Nasional

Artikel menyebut bahwa Indonesia telah menetapkan target **penggunaan energi terbarukan mencapai 40% pada 2050**, dan biomassa menjadi tulang punggungnya. Model prediksi ini bisa digunakan oleh:

- **Pemerintah**, untuk memetakan wilayah dengan potensi tinggi biomassa.
- **Pengusaha dan investor**, untuk **menghitung proyeksi output energi** sebelum memutuskan lokasi dan skala investasi.
- **Peneliti**, sebagai basis untuk analisis potensi lokal berdasarkan variabel input riil.

Dengan integrasi model prediksi, Indonesia dapat **mengurangi ketergantungan pada teknologi impor** (salah satu hambatan dalam artikel), dan **menghasilkan sistem lokal berbasis data** yang terjangkau dan efektif.

4. Kesesuaian Output Model dengan Target PLTBm Nasional

Artikel menjelaskan bahwa PLTBm Siantan di Kalimantan Barat memiliki kapasitas besar, dan pemerintah menargetkan peningkatan kapasitas listrik biomassa secara bertahap:

- 2025: 20% dari total potensi → ~6 GW
- 2050: 90% → ~22 GW

Model yang menghasilkan akurasi prediksi tinggi ($R^2 = 99,36\%$) dapat digunakan untuk **mengestimasi secara mikro**: misalnya output dari desa, kabupaten, atau provinsi, untuk mengakumulasi estimasi makro secara nasional.

5. Solusi Terhadap Hambatan: SDM & Teknologi

Salah satu hambatan yang disebut dalam artikel adalah **kurangnya SDM teknis dan ketergantungan pada teknologi luar negeri**. Model prediksi yang dikembangkan di Python dengan library open-source (scikit-learn, pandas, seaborn) menjadi **contoh nyata solusi berbasis teknologi lokal** yang bisa:

- Diterapkan tanpa biaya lisensi tinggi
- Diajarkan kepada mahasiswa dan teknisi muda
- Diadaptasi untuk **dashboard energi desa berbasis biomassa**

2.6.2 INTERPRETASI TERHADAP DUNIA NYATA(PERTANIAN DAN ENERGI)

IMPLIKASI TERHADAP DUNIA NYATA

Model prediksi energi biomassa yang telah dibangun dan dievaluasi secara komprehensif memiliki sejumlah **implikasi nyata** dalam berbagai sektor — mulai dari pemerintahan, industri, pertanian, hingga masyarakat umum. Berikut ini uraian dampaknya:

1. Perencanaan dan Pemetaan Potensi Energi Daerah

Model ini memungkinkan pemerintah daerah maupun pusat untuk:

- Melakukan **pemetaan wilayah dengan potensi energi biomassa tinggi** berdasarkan data berat dan kadar air limbah pertanian lokal.
- **Mengklasifikasikan jenis limbah** mana yang paling optimal untuk dikonversi menjadi energi.
- Merancang **roadmap pengembangan energi desa berbasis biomassa**, sebagai bagian dari program elektrifikasi pedesaan.

Contoh nyata: Desa-desa penghasil singkong atau jerami bisa diprioritaskan untuk pendirian PLTBm mikro karena prediksi output energi sudah tersedia dari model.

2. Efisiensi Investasi dan Feasibility Study

Dalam sektor swasta dan pengusaha bioenergi:

- Model ini bisa digunakan untuk **menghitung estimasi energi** sebelum pembangunan pabrik atau pembangkit.
- Mengurangi biaya studi kelayakan yang biasanya mahal dan lama.
- Menjadi dasar kuantitatif untuk **menarik investor**, dengan menunjukkan proyeksi energi yang kredibel.

Implikasi: Investor dapat menggunakan output prediksi untuk menghitung ROI dari proyek biomassa secara akurat dan berbasis data.

3. Transformasi Pertanian Menjadi Sumber Energi

Bagi petani dan koperasi pertanian:

- Dapat mengetahui **nilai ekonomis dari limbah hasil panen** seperti sekam padi, kulit kopi, jerami, dll.
- Mendorong perubahan persepsi bahwa limbah bukan beban, melainkan **aset energi**.
- Memicu **integrasi pertanian dan energi** dalam satu rantai pasok yang saling menguntungkan.

Dampak nyata: Petani bisa menjual limbahnya ke unit konversi biomassa atau menggunakannya sendiri untuk kebutuhan energi lokal.

4. Akselerasi Transisi Energi Nasional

Program prediksi ini mendukung target pemerintah Indonesia yang ingin meningkatkan proporsi energi terbarukan hingga 40% pada tahun 2050. Dengan:

- Data prediktif yang presisi untuk menyusun **peta jalan energi biomassa nasional**.
- Menjadi komponen utama dalam platform perencanaan berbasis digital oleh Kementerian ESDM atau PLN.

Tanpa alat prediksi seperti ini, pengambilan kebijakan energi biomassa akan bersifat reaktif dan tidak terukur.

5. Peningkatan Kapasitas SDM dan Teknologi Lokal

Model ini dibangun dengan teknologi open-source seperti Python, Scikit-learn, dan Pandas, yang:

- **Mudah diakses dan dipelajari oleh pelajar, mahasiswa, dan tenaga teknis lokal.**
- Dapat menjadi bahan ajar dalam pelatihan data science sektor energi.
- Mendorong kemandirian teknologi dan **mengurangi ketergantungan pada software asing.**

Implikasi pendidikan: Sekolah vokasi, politeknik, dan kampus bisa mengadopsi proyek ini sebagai studi kasus nasional.

6. Solusi Terhadap Hambatan Lingkungan dan Emisi

Model ini memungkinkan pendekatan berbasis data untuk:

- **Mengurangi pembakaran terbuka limbah pertanian**, yang sering menimbulkan polusi udara dan gas rumah kaca.
- Mengonversi limbah menjadi energi dengan efisiensi tinggi dan **dampak emisi nol (carbon-neutral)**.
- Mendukung aksi iklim nasional dan agenda SDGs (Sustainable Development Goals).

Dampak ekologi: Konversi biomassa yang tepat akan menurunkan emisi karbon dan mendukung pemulihan iklim.

7. Mendukung Kebijakan & Insentif Pemerintah

Output model ini dapat digunakan sebagai:

- **Dasar pemberian subsidi atau insentif** oleh pemerintah untuk daerah dengan potensi tinggi biomassa.
- Alat bantu kuantitatif dalam merancang **harga keekonomian energi biomassa**, agar lebih kompetitif dibanding energi fosil.
- Alat bantu evaluasi untuk kebijakan seperti **Perpres No. 79/2014** dan **UU Energi No. 30/2007**.

Implikasi kebijakan: Pemerintah bisa menargetkan investasi lebih tajam dan efisien pada wilayah prioritas.

Kesimpulan Implikasi Dunia Nyata

Model prediksi energi biomassa ini bukan sekadar inovasi teknis, tetapi merupakan **alat strategis** untuk:

- Mendukung kebijakan energi nasional
- Mengarahkan investasi yang presisi
- Mengubah limbah menjadi sumber energi terukur
- Mengintegrasikan pertanian dengan sektor energi
- Mendorong edukasi teknologi tepat guna
- Dan paling penting: **mewujudkan transisi energi yang adil, cerdas, dan berkelanjutan**

BAB III

PENUTUP

3.1 KESIMPULAN

Penelitian ini membuktikan bahwa algoritma **Random Forest** merupakan metode yang efektif untuk memprediksi **potensi energi terbarukan dari limbah pertanian**. Dengan memanfaatkan data seperti jenis limbah, berat, dan kadar air, model yang dibangun mampu menghasilkan prediksi energi yang akurat dan stabil. Proses pra-pemrosesan data dan analisis eksploratif membantu memastikan bahwa data yang digunakan berkualitas dan relevan, sementara Random Forest memberikan fleksibilitas dalam menangani data kompleks tanpa risiko overfitting yang tinggi.

Model ini memiliki potensi aplikasi yang luas dalam dunia nyata, mulai dari membantu pemerintah dalam pemetaan energi biomassa, mendukung perencanaan investasi bioenergi, hingga memberikan nilai tambah bagi petani melalui pemanfaatan limbah sebagai sumber energi. Selain itu, model ini mendukung agenda nasional dalam transisi energi terbarukan dan dapat dikembangkan lebih lanjut menjadi sistem prediksi yang terintegrasi secara digital.

Secara keseluruhan, penggunaan Random Forest dalam proyek ini menunjukkan bahwa teknologi machine learning dapat menjadi alat strategis untuk mendorong pemanfaatan limbah pertanian secara berkelanjutan dan bernilai ekonomi tinggi.

DAFTAR PUSTAKA

- dqlab.id. (2025, Januari 16). *Mengapa Data Preprocessing Penting dalam Machine Learning?* From dqlab.id: <https://dqlab.id/mengapa-data-preprocessing-penting-dalam-machine-learning>
- Erin. (2024, April 02). *Random Forest vs Decision Tree*. From sis.binus.ac.id: <https://sis.binus.ac.id/2024/04/02/random-forest-vs-decision-tree/>
- Tauran, E. (2023, 12 23). *Apa Itu Exploratory Data Analysis? Berikut Penjelasannya*. From danacita.co.id: <https://danacita.co.id/blog/apa-itu-exploratory-data-analysis/>